

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет экономических наук

Проектная работа по дисциплине
"Эконометрика 2 (углубленный курс)" на тему:
"Оценивание гедонистической ценовой функции для автомобилей с
помощью моделей множественной регрессии"

ФИО	Группа	Вклад	Выполненные задачи
Иванова М.	БЭК223	33.(3)%	• Проверка спецификации моделей, тесты • Проверка гипотезы о нормальности случайных ошибок • Выбор наилучшую модель и описание выводов • Оформление отчета
Салман Я.	БЭК223	33.(3)%	• Оформление данных: описательные статистики, графики, код и отчет • Выбор функциональной формы, тестирование функциональных форм • Проверка нулевого матожидания ошибок регрессии • Оформление отчета
Юманова А.	БЭК225	33.(3)%	• Парсинг, очистка и описание данных • Проверка независимости ошибок • Проверка гипотезы о значимости коэффициентов и модели в целом • Доп анализ других спецификаций • Оформление отчета и гитхаба

Github:
https://github.com/Aurumlin/Econ_metrics_project/tree/main

Руководители:
Вакуленко Е.С.
Погорелова П.В.

1	Введение	2
1.1	Описание переменных	2
1.1.1	Зависимая переменная	2
1.1.2	Независимые переменные	2
1.1.3	Географическая характеристика	2
1.1.4	Производные признаки	2
1.2	Первичный анализ данных	3
2	Основная часть	3
2.1	Предпосылки	3
2.1.1	Первичный выбор функциональной формы и признаков	3
2.1.2	Нормальность остатков	4
2.1.3	Проверка спецификации модели	5
2.1.4	Тест на полноранговость матрицы	5
2.1.5	Тест на независимость ошибок	6
2.1.6	Проверка нулевого математического ожидания ошибок	6
2.1.7	Проверка значимости коэффициентов	6
2.1.8	Проверка значимости модели в целом	6
2.2	Оценивание итоговой модели и ее интерпретация	6
2.3	Построение предсказания и его доверительного интервала	6
2.3.1	Характеристики автомобиля	6
2.3.2	Результаты предсказания	7
2.3.3	Интерпретация результатов	7
3	Модель квантильной регрессии	7
3.1	Мотивация выбора модели	7
3.2	Построение модели	7
3.3	Интерпретация результатов	7
3.4	Выводы	8
4	Заключение	8
5	Приложение 0	8
6	Приложение 1	9
7	Приложение 2	9

1 Введение

1.1 Описание переменных

1.1.1 Зависимая переменная

Целевая переменная - цена автомобиля, в рублях. В данных были как точные цены, так и ценовые диапазоны. Для учета этого мы используем две переменные: «Цена от, руб» и «Цена до, руб». Для автомобилей с фиксированной ценой значения в обоих столбцах совпадают, а для автомобилей с ценовым диапазоном они содержат минимальную и максимальную цены. Мы будем использовать среднюю цену автомобиля, рассчитанную как среднее значение между минимальной и максимальной ценами для автомобилей с ценовым диапазоном, и фиксированную цену для остальных автомобилей.

1.1.2 Независимые переменные

В собранных данных представлены различные характеристики автомобилей, которые потенциально могут влиять на их рыночную стоимость:

Технические характеристики

- **Мощность двигателя** представлена двумя показателями: объёмом в литрах (*power_1*, диапазон значений: от 1.3 до 2.4) и мощностью в лошадиных силах (*power_2*, диапазон значений: от 83 до 249). Объём двигателя влияет на расход топлива, а мощность определяет динамические характеристики автомобиля.
- **Тип топлива** (*fuel_type*) — категориальная переменная, указывающая на используемое автомобилем топливо (бензин, дизель, гибрид, электричество и т.д.). Данный параметр существенно влияет на экономичность автомобиля.
- **Коробка передач** (*gearbox*) — категориальная переменная, определяющая тип трансмиссии (механическая, автоматическая, роботизированная, вариатор).
- **Привод** (*drive*) — категориальная переменная, указывающая на тип привода автомобиля (передний, задний, полный).

Визуальные и идентификационные характеристики

- **Марка** (*brand*) — категориальная переменная, содержащая информацию о производителе автомобиля.
- **Модель** (*model*) — категориальная переменная, указывающая модельный ряд в рамках конкретной марки.
- **Цвет кузова** (*color*) — категориальная переменная, отражающая цветовое решение автомобиля, что может влиять на его рыночную стоимость.

Эксплуатационные характеристики

- **Пробег** (*mileage*) — количественная переменная, отражающая степень износа автомобиля в километрах. Для новых автомобилей значение указано как «Новый». Диапазон значений: от 0 (новый) до 58 000 км.
- **Год выпуска** (*year*) — количественная переменная, указывающая год производства автомобиля. Этот параметр отражает устаревание модели.

1.1.3 Географическая характеристика

- **Город продажи** (*city*) — категориальная переменная, отражающая место продажи автомобиля. Важна для учета региональных особенностей.

1.1.4 Производные признаки

- **Возраст автомобиля** (*age*, числовая) — измеряется в годах, рассчитан как 2025 минус год выпуска (диапазон значений: от 0 до 14).
- **Поколение** (*generation*, числовая) — диапазон значений: от 1 до 4. Указывает на эволюцию модели.
- **Популярность модели** (*model_popularity*, числовая) — измеряется количеством упоминаний в датасете (диапазон значений: от 1 до 319). Отражает востребованность модели на рынке.
- **Группа цветов** (*color_group*, категориальная) — Нейтральные, Холодные, Тёплые, Экзотические. Используется для упрощения анализа цветовых предпочтений.
- **Группа городов** (*city_group*, категориальная) —например, Москва, Московская область, Ближние регионы. Используется для анализа географических трендов.
- **Базовая модель** (*base_model*, категориальная) — базовое название модели (например, Tiggo, H3, Monjaro).
- **Класс автомобиля** (*car_class*, категориальная) — например, SUV, Crossover, Other. Уникальные значения: 4. Отражает сегмент автомобиля на рынке.
- **Удельная мощность** (*power_density*, числовая) — расчётный показатель, полученный как отношение мощности двигателя в лошадиных силах к объёму двигателя в литрах (диапазон значений: зависит от *power_1* и *power_2*). Характеризует эффективность двигателя.
- **Флаг нового автомобиля** (*is_new*, бинарная) — флаг, указывающий, является ли автомобиль новым (True/False). Уникальные значения: 2. Используется для разделения новых и подержанных автомобилей.
- **Флаг рестайлинга** (*is_restyling*, бинарная) — флаг, указывающий на наличие рестайлинга (1 — есть, 0 — нет). Уникальные значения: 2. Отражает обновление модели.
- **Флаг версии Pro/Max** (*is_pro / is_max*, бинарная) — флаг, указывающий на наличие версии Pro/Max (1 — есть, 0 — нет).
- **Флаг премиум-версии** (*is_premium*, бинарная) — флаг, указывающий на наличие премиум-версии (1 — есть, 0 — нет).. Отражает повышенный уровень оснащения.

1.2 Первичный анализ данных

Графики и таблицы для этого раздела находятся в Приложении 2.

Статистические характеристики признаков (таб. 2-4) позволяют выделить ключевые особенности выборки. Средний пробег (*mileage*) составляет 25 193 км, но высокий разброс (до 283 000 км) указывает на присутствие как новых, так и подержанных автомобилей. Объём двигателя (*power_1*) и мощность (*power_2*) сосредоточены вокруг 1.5 л и 177 л.с., что характерно для автомобилей среднего класса. Средний возраст составляет 2.08 года, но встречаются и модели старше 10 лет. Цена варьируется от 150 000 до 4 599 000 рублей, медиана — 2 317 000.

Анализ корреляций между переменными (см. Рис.8

Сильные корреляции (>0.7 или <-0.7):

- *Положительные:*
 - power_1 и power_2 (0.76) - объём двигателя связан с мощностью
 - power_2 и is_premium (0.82) - премиальные версии имеют более мощные двигатели
 - model_popularity и is_premium (0.70) - популярные модели чаще премиальные
- *Отрицательные:*
 - mileage и age (0.72) - чем старше авто, тем больше пробег
 - power_2 и age (-0.54) - новые модели мощнее старых

Умеренные корреляции (0.5-0.7):

- *Положительные:*
 - power_1 и is_premium (0.70)
 - is_restyling и power_2 (0.43) - рестайлинговые версии мощнее
 - is_pro и is_max (0.60) - эти флаги часто вместе
- *Отрицательные:*
 - mileage и is_premium (-0.31) - премиальные авто с меньшим пробегом
 - is_pro и is_premium (-0.28) - редко встречаются вместе

Слабые корреляции (<0.5):

- is_new почти не коррелирует ни с чем
- is_restyling положительно влияет на популярность (0.41)
- is_max слабо связан с мощностью двигателя (0.14)

Теперь проанализируем регрессоры, основные выводы:

Аспект анализа	Основные выводы
Распределение цен (рис.1)	
Характеристики распределения	• Медиана и среднее близки (разница=27 тыс. руб.) • Мода: 2.8 млн руб. • Skewness=−0.04 (слабая левосторонняя асимметрия) • Kurtosis=0.74 (остроконечное распределение) • Основной диапазон: 2.3-2.8 млн руб.
Категориальные переменные (рис.3-5)	
Марка	Geely дороже, Chery дешевле среднего
Цвет	Холодные оттенки дороже, теплые/экзотические дешевле
КПП	Автомат дороже, механика/вариатор дешевле
Привод/Топливо	Полный привод и дизель/гибрид дороже
География	Москва: максимум предложений и цен
Класс	Crossover самый дорогой
Числовые переменные (рис.2)	
Пробег	Обратная корреляция с ценой (пик 0-28 тыс.км)
Мощность	Положительное влияние (2 л - типичное значение)
Возраст	Обратная зависимость от цены (основной диапазон до 7 лет)
Бинарные признаки (рис.6-7)	
Is New	Неинформативен (99% случаев "нет")
Рестайлинг	+50% стоимости
Флаги	is premium дороже, is pro/max дешевле

Также в приложении представлены другие графики (связь бинарных и категориальных признаков, бинарных и числовых)

2 Основная часть

2.1 Предпосылки

В основной работе мы решили предварительно отобрать признаки для модели (см. далее), однако нам также хотелось опробовать другие спецификации (линейные, логарифмированные, полулог модели) и сравнить их по AIC-BIC. Эту часть мы вынесли ближе к приложениям, как факультативную. См. Приложение 0.

2.1.1 Первичный выбор функциональной формы и признаков

1. Удаление бесполезных признаков:

- Исключены: generation, is_new, model_popularity
- Категориальные переменные с большим числом уникальных значений (city, color, base_model) заменены на агрегированные группы: color_group, city_group, brand
- Обоснование: признаки были удалены в связи с тем, что на этапе графического анализа оказались бесполезны (например, плохая объясняющая способность, преобладает одно уникальное значение и т.п.), а замена на группы для признаков с большим числом категорий нужна для упрощения дальнейшего отбора.

2. Трансформация целевой переменной:

- Логарифмирование цены: ln(Y)
- Обоснование: устранение асимметрии распределения из-за экстремальных значений, которые были обнаружены при первичном анализе, также это позволило повысить интерпретируемость коэффициентов модели (см. блокнот)

3. Устранение мультиколлинеарности:

- Удалены признаки с корреляцией > 0.8

4. Отбор основан на экономической интерпретируемости:

- Среди оставшихся признаков были отобраны, те которые имели неплохую экономическую интерпретацию (например, возраст автомобиля действительно, как правило, вызывает снижение стоимости, а рестайлинг, наоборот, повышает)

По итогу были отобраны следующие признаки:`log_age`, `brand_Geely`, `is_restyling`, `color_group_Холодные`, `log_power`, `city_group_Москва`, `gearbox_Механика`, `drive_полный`, `car_class_Crossover`

2.1.2 Нормальность остатков

[Содержание подраздела]

Тест Бройша–Пагана

Для проверки наличия гетероскедастичности в модели был проведён тест Бройша–Пагана. Статистика теста определяется как:

$$BP = \frac{ESS}{2} \sim \chi_p^2,$$

где ESS — сумма квадратов объяснённой части в вспомогательной регрессии:

$$\frac{\varepsilon_i^2}{\hat{\sigma}^2} = \gamma_0 + \gamma_1 Z_{1i} + \dots + \gamma_p Z_{pi} + u_i,$$

в которой $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \varepsilon_i^2$, а ε_i — остатки, полученные из исходной регрессии.

Гипотезы теста

- H_0 : Ошибки имеют постоянную дисперсию (гомоскедастичность).
- H_1 : Ошибки имеют переменную дисперсию (гетероскедастичность).

Результаты теста

- LM-статистика: 100.2656
- р-значение LM-статистики: 0.0000
- F-статистика: 11.9685
- р-значение F-статистики: 0.0000

Вывод

Так как р-значение теста значительно меньше принятого уровня значимости $\alpha = 0.05$, нулевая гипотеза об отсутствии гетероскедастичности отвергается. Таким образом, в модели обнаружена гетероскедастичность.

График остатков от предсказанных значений дополнительно подтверждает вывод (рис. 13).

Для корректного учёта наличия гетероскедастичности в модели далее применим оценку робастных стандартных ошибок типа HC3 (рис.14).

Тест Уайта

Статистика теста вычисляется по формуле:

$$W = nR^2 \sim \chi_{m-1}^2,$$

где R^2 — коэффициент детерминации из регрессии квадратов остатков исходной модели на все регрессоры, их квадраты, попарные произведения и константу, а m — количество параметров в этой вспомогательной регрессии.

Гипотезы теста

- H_0 : Ошибки имеют постоянную дисперсию (гомоскедастичность).
- H_1 : Ошибки имеют переменную дисперсию (гетероскедастичность).

Результаты теста

- LM-статистика: 703.2339
- р-значение LM-статистики: 0.0000
- F-статистика: 31.6866
- р-значение F-статистики: 0.0000

Вывод

- присутствует **гетероскедастичность** в модели согласно тесту Уайта.

Робастные стандартные ошибки

Для борьбы с возможной гетероскедастичностью используем оценку робастных стандартных ошибок типа HC3. Это поможет сделать выводы по значимости коэффициентов более надёжными. Рис. ??

P-value коффициентов не превысили уровень значимости, все коэффициенты по-прежнему значимы, а оценки более надежны. R-квадрат такой же высокий.

2.1.3 Проверка спецификации модели

Гипотезы и статистики используемых тестов представлены в Приложении 1.

Ошибки спецификации:

- 1. Пропуск важной переменной – > Тест Рамсея
- 2. Включение лишней переменной – > F-тест на группу незначимых переменных
- 3. Выбор неправильной функциональной формы – > Построение моделей, тест Бокса-Кокса, РЕ тест, тестирование нормальности остатков.

Проверка спецификации модели
Пропуск важной переменной

- 1. Построена базовая линейная модель с числовыми и бинарными признаками.

Результат:

p-value = 0.0000, F-stat = 244.7197

То есть H_0 отвергается: спецификация модели некорректна.

- 2. Изменяем функциональную форму модели: логарифмируем зависимую переменную *price*, добавляем квадраты признаков *age*, *mileage*, *power*₁, *power*₂.

Результат:

p-value = 0.0000, F-stat = 88.2495

То есть H_0 отвергается: спецификация остаётся неверной.

- 3. Добавляем взаимодействия: *power*₁ × *age*, *power*₂ × *mileage*, *model_popularity* × *age*.

Результат:

p-value = 0.0001, F-stat = 15.6909

То есть H_0 отвергается: спецификация по-прежнему некорректна.

Выводы:

- 1. Базовая модель отвергает гипотезу о корректной спецификации.
- 2. Логарифмирование и добавление квадратичных признаков улучшают модель, но не устраняют проблему спецификации.
- 3. Включение взаимодействий снижает ошибку и повышает гибкость модели, но RESET-тест всё ещё указывает на неверную спецификацию.
- 4. Возможно, существует более сложная нелинейная зависимость, не учтённая в текущей модели.

Включение лишней переменной

Проведён *F*-тест на значимость группы переменных: *power*₂, *generation*, *is_max*, *is_pro*.

Результат:

p-value = NaN

Интерпретация: Значимого ухудшения модели после исключения переменных не обнаружено.

Вывод: Группа переменных статистически незначима и может быть исключена без ухудшения качества модели.

Тест на нормальность остатков

Тест Бокса–Кокса для переменной *price*

Результат: $\lambda = 0.9096$ Интерпретация: Поскольку $\lambda \approx 1$, трансформация *price* не обязательна.

Вывод: Использование оригинальной формы переменной допустимо.

Тест Шапиро–Уилка на нормальность остатков

Результат:

W-stat = 0.9688, p-value = 0.0000

Интерпретация:

p-value < 0.05 ⇒ отвергаем H_0

Остатки не нормально распределены.

Вывод: Нарушена предпосылка нормальности ошибок. Однако это было учтено при пересчёте модели с робастными стандартными ошибками (НСЗ).

РЕ-тест на ненулевое среднее ошибки

Результат:

T-stat = 0.0000, p-value = 1.0000

Интерпретация:

p-value > 0.05 ⇒ не отвергаем H_0

Ошибки в среднем равны нулю.

Вывод: Модель не имеет систематического смещения. Прогнозы в среднем корректны.

2.1.4 Тест на полноранговость матрицы

Результаты теста

- Ранг матрицы: 10
- Количество столбцов: 10

Вывод

- H_1 : Матрица регрессоров **X** является полноранговой (все столбцы линейно независимы)

2.1.5 Тест на независимость ошибок

График стандартизированных остатков против предсказанных значений показал некоторую нелинейную зависимость, мы попытались исправить это в модели с робастными ошибками.

Вывод

Предпосылка независимости ошибок не подтверждается визуально.

2.1.6 Проверка нулевого математического ожидания ошибок

В модели присутствует константа, что гарантирует выполнение условия $E(\varepsilon_i) = 0$ при МНК-оценивании. Среднее значение остатков статистически не отличается от нуля (p-значение t-теста = 0.99).

Вывод

Предпосылка о нулевом математическом ожидании ошибок подтверждается.

2.1.7 Проверка значимости коэффициентов

Для каждого коэффициента β_i проверялась гипотеза:

$$H_0 : \beta_i = 0 \quad \text{vs} \quad H_1 : \beta_i \neq 0$$

на основе t-статистики.

По результатам:

- Коэффициенты при переменных `log_age`, `brand_Geely`, `is_restyling`, `color_group_Холодные`, `log_power_2`, `city_group_Москва`, `gearbox_механика`, `drive_полный`, `car_class_Crossover` оказались статистически значимыми при уровне значимости $\alpha = 0.05$ (p-значение меньше 0.05).
- Незначимых коэффициентов среди выписанных переменных не обнаружено (все переменные значимы).

2.1.8 Проверка значимости модели в целом

Гипотеза о незначимости всей регрессионной модели:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \quad \text{vs} \quad H_1 : \exists \beta_j \neq 0$$

проверялась с помощью F-теста.

- F-статистика: 1216.0
- p-значение: 0.0000

Вывод

При уровне значимости $\alpha = 0.05$, p-значение F-теста составляет 0.0000, что:

- меньше $\alpha \rightarrow$ модель в целом статистически значима.

2.2 Оценивание итоговой модели и ее интерпретация

$$\begin{aligned} \log(\text{price}) = & 11.3904 - 0.3728 \log(\text{age}) + 0.0531 \text{brand_Geely} + 0.0477 \text{is_restyling} + 0.0824 \text{color_group_Холодные} \\ & + 0.6618 \log(\text{power_2}) + 0.0515 \text{city_group_Москва} - 0.7501 \text{gearbox_механика} + 0.0542 \text{drive_полный} - 0.0463 \text{car_class_Crossover} + \epsilon \end{aligned} \tag{1}$$

Интерпретация коэффициентов

- **Константа (11.3904)**: Базовое значение логарифма цены при нулевых значениях всех предикторов.
- **log(age) (-0.3728)**: При увеличении логарифма возраста автомобиля на 1%, цена уменьшается на 0.37% (при прочих равных).
- **brand_Geely (0.0531)**: Автомобили марки Geely в среднем на 5.3% дороже ($\exp(0.0531) - 1.0546$).
- **is_restyling (0.0477)**: Наличие нового стиля увеличивает цену на 4.8%.
- **color_group_Холодные (0.0824)**: Автомобили цвета Хонqube дороже на 8.6%.
- **log(power_2) (0.6618)**: Увеличение логарифма квадрата мощности на 1% связано с ростом цены на 0.66%.
- **city_group_Москва (0.0515)**: Автомобили из города Москва дороже на 5.3%.
- **gearbox_механика (-0.7501)**: Коробка передач мкханика снижает цену на 52.8% ($1 - \exp(-0.7501) - 0.528$).
- **drive_полный (0.0542)**: Полный привод увеличивает цену на 5.6%.
- **car_class_Crossover (-0.0463)**: Кроссоверы дешевле на 4.5%.

2.3 Построение предсказания и его доверительного интервала

2.3.1 Характеристики автомобиля

Для нового наблюдения были заданы следующие параметры:

- Возраст: 2 ($\log(\text{age}) \approx 0.693$)
- Марка: Geely (`brand_Geely = 1`)
- Рестайлинг: Нет (`is_restyling = 0`)
- Цвет: Холодные (`color_group_Холодные = 1`)
- Мощность: 19 ($\log(\text{power_2}) \approx 2.944$)

Параметр	Значение
Предсказание $\log(\text{price})$	15.2159
95% ДИ для $\log(\text{price})$	[14.8432, 15.5886]
Предсказание цены	4 056 637.95 RUB
95% ДИ для цены	[2 794 539.51 RUB, 5 888 738.17 RUB]

Таблица 1: Результаты предсказания цены

2.3.2 Результаты предсказания

Модель выдала следующие результаты:

2.3.3 Интерпретация результатов

На основании построенной модели можно сделать следующие выводы:

- Автомобиль с указанными характеристиками имеет предсказанную стоимость около 4 лн RUB
- С вероятностью 95% истинная цена автомобиля находится в диапазоне от 2.79 RUB до 5.89 RUB
- Широкий доверительный интервал (3 лн RUB) может быть обусловлен:
 - Высокой дисперсией цен на автомобили с подобными характеристиками
 - Влиянием неучтённых в модели факторов

$$\log(\text{price}) = 15.2159 \pm 0.3727 \quad (\text{при } 95\% \text{ доверительной вероятности}) \tag{2}$$

3 Модель квантильной регрессии

3.1 Мотивация выбора модели

В рамках исследования наряду с классической линейной регрессией целесообразно применение квантильной регрессии, что обусловлено следующими факторами:

- Нарушение предпосылки о нормальности распределения ошибок (тест Шапиро-Уилка: $p\text{-value} \approx 0$)
- Наличие гетероскедастичности (тесты Бройша-Пагана и Уайта: $p\text{-value} = 0.0000$)
- Наличие выбросов и асимметрия в распределении цен (коэффициент асимметрии -0.04 , эксцесс -0.74)
- Необходимость анализа влияния факторов на разные части ценового распределения

3.2 Построение модели

Построение модели квантильной регрессии подразумевает минимазацию следующей функции потерь:

$$\sum_{i=1}^n \rho_q(y_i - \mathbf{x}_i^\top \boldsymbol{\beta}_q),$$

где $\rho_q(u)$ — функция потерь для квантильной регрессии, определяемая как:

$$\rho_q(u) = \begin{cases} q \cdot |u|, & \text{если } u \geq 0, \\ (1 - q) \cdot |u|, & \text{если } u < 0. \end{cases}$$

Пояснение:

- $\mathbf{y}$ — вектор зависимой переменной размера $n \times 1$,
- $\mathbf{X}$ — матрица регрессоров размера $n \times p$,
- $\boldsymbol{\beta}_q$ — вектор коэффициентов квантильной регрессии для квантиля q ,
- $\mathbf{x}_i^\top$ — i -я строка матрицы $\mathbf{X}$,
- $u = y_i - \mathbf{x}_i^\top \boldsymbol{\beta}_q$ — остаток.

Модель будет оцениваться для следующих квантилей: 5%, 10%, 25%, 50%, 75%, 90% и 95%. Также отметим, что как и ранее мы будем использовать логарфмированный таргет, поэтому интерпретация коэффициентов имеет важную особенность:

- Эффект независимой переменной выражается через **процентное изменение таргета** по формуле:

$$\Delta Y = (e^{\beta_i} - 1) \times 100\%$$

где β_i — коэффициент регрессии.

3.3 Интерпретация результатов

Были выявлены следующие закономерности (см. Рис. 11):

- **log_age**:
 - Отрицательные коэффициенты для большинства квантилей (0.05–0.5) указывают на обратную зависимость между возрастом автомобиля и его ценой.
 - Резкое снижение абсолютного значения коэффициента при $\tau = 0.75$ (-0.20) может свидетельствовать о нелинейности влияния возраста на верхние квантили цен.
- **brand_Geely**:




Рис. 1: Графики остатки-прогнозы для лин, лин-лог, лог моделей

- Положительное влияние на нижние квантили ($\tau = 0.05$: 0.12) сменяется отрицательным для $\tau = 0.95$ (-0.025). Это указывает на то, что бренд Geely ассоциируется с более низкими ценами в премиальном сегменте.

- **is_restyling:**

- Рестайлинг положительно влияет на цены для $\tau = 0.05$ –0.5 (коэффициенты 0.20–0.045). Для $\tau = 0.75$ эффект статистически незначим (близок к нулю).

- **color_group_Холодные:**

- Значимый рост коэффициента при $\tau = 0.95$ (0.22) позволяет предположить, что холодные цвета повышают стоимость автомобилей в верхнем ценовом сегменте.

- **log_power_2:**

- Стабильно положительные коэффициенты (0.63–0.93) подтверждают ожидаемую зависимость: мощность двигателя положительно коррелирует с ценой на всех уровнях квантилей.

- **gearbox_механика:**

- Сильное отрицательное влияние (-1.05 при $\tau = 0.75$) указывает на то, что механическая коробка передач ассоциируется со снижением цены, особенно в средних и верхних квантилях.

- **drive_полный:**

- Смешанные коэффициенты (от -0.003 до 0.097) с пересекающими нуль доверительными интервалами. Влияние полного привода статистически неоднозначно.

3.4 Выводы

В рамках данного исследования была построена и проанализирована модель, объясняющая формирование цен на автомобили на вторичном рынке. Работа охватила весь цикл эконометрического анализа: от подготовки данных и отбора признаков до проверки предпосылок, тестирования спецификации модели и построения альтернативных моделей.

- Наибольшее влияние на цены оказывают технические характеристики (мощность, тип коробки передач), тогда как географический фактор (city_group_Москва) статистически незначим.
- Значимость переменных варьируется в зависимости от квантиля. Например, бренд Geely демонстрирует противоположные эффекты для нижних и верхних квантилей.
- Ширина доверительных интервалов (особенно для color_group_Холодные и car_class_Crossover) указывает на необходимость осторожной интерпретации этих переменных.
- **Логарифмическая трансформация переменной цены** ($\log(\text{price})$) оказалась оправданной: она улучшила нормальность остатков и сделала интерпретацию коэффициентов интуитивно понятной (в процентах).
- **Проверка спецификации модели** с помощью теста Рамсея показала наличие пропущенных переменных в исходной модели. Добавление квадратичных и перекрёстных признаков привело к улучшению спецификации, однако нормальность остатков нарушена (тест Жака-Бера), что требует использования робастных стандартных ошибок.

Направления дальнейших исследований

- Расширение модели с использованием методов машинного обучения может улучшить точность предсказания цен.
- Интеграция текстовых и визуальных данных об автомобиле с помощью методов обработки естественного языка и компьютерного зрения может значительно улучшить модель.
- Анализ временных и региональных паттернов ценообразования потребует добавления данных по дате публикации и географии.

4 Заключение

Построенная модель обладает высокой интерпретируемостью, хорошей прогностической способностью и отвечает большинству требований эконометрической корректности. Она может быть использована как в академических исследованиях, так и в практической оценке стоимости автомобилей.

5 Приложение 0

Оценили дополнительно линейную, лог и полулог модели на признаках, которые мы отобрали ранее. Также числовые признаки отнормировали. Признаки: log_age, brand_Geely, is_restyling, color_group_Холодные, log_power, city_group_Москва, gearbox_Механика, drive_полный, car_class_Crossover.

Код и проверки - в файле additional_models.

Отличие лог модели и выбранной ранее: в лог модели числовые логарифмированные признаки были нормированы.

По критерию BIC-AIC выигрывает лог-лог модель, уступая лишь выбранной нами ранее, у которой этот информационный критерий отрицателен. Исследование VIF не дало нового знания. Тесты на нормальность показали ненормальность остатков для всех моделей. По графику остатки-прогнозы явно видно ненормальность распределения остатков для моделей с логарифмами и нормированными признаками. Тест Бокс-Кокса с преобразованием зарембки также показал, что лучше работает лог модель без скейлинга оп сравнению с скейлингом. PE тест МакКиннона, Уайта и Дэвидсона (1983) подтвердил необходимость логарифмирования признаков.

Вывод: тесты показали, что логарифмирование признаков необходимо, а также провалидировали наш изначальный выбор модели.

6 Приложение 1

Описание статистик и гипотез используемых тестов:

1. Тест Рамсея (RESET-тест)

Цель: Проверка правильности спецификации модели (включены ли нужные переменные и учтены ли нелинейности).

Модель:

$$y = \beta_0 + \beta_1x_1 + \cdots + \beta_kx_k + \gamma_1\hat{y}^2 + \gamma_2\hat{y}^3 + \varepsilon$$

Гипотезы:

$$H_0 : \gamma_1 = \gamma_2 = 0 \quad (\text{модель специфицирована верно}) H_1 : \gamma_i \neq 0 \text{ хотя бы для одного } i \quad (\text{модель специфицирована неверно})$$

F-статистика:

$$F = \frac{(RSS_R - RSS_U)/q}{RSS_U/(n - k - q - 1)} \sim F_{q,n-k-q-1}$$

2. F-тест на значимость группы переменных

Цель: Оценить необходимость включения группы переменных в модель.

Гипотезы:

$$H_0 : \beta_{j_1} = \beta_{j_2} = \cdots = \beta_{j_q} = 0 H_1 : \text{ хотя бы один } \beta_{j_i} \neq 0$$

F-статистика:

$$F = \frac{(RSS_R - RSS_F)/q}{RSS_F/(n - k)} \sim F_{q,n-k}$$

3. Тест Бокса–Кокса

Цель: Найти подходящую трансформацию зависимой переменной y для устранения нелинейности.

Преобразование:

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda}, & \lambda \neq 0 \\ \ln(y), & \lambda = 0 \end{cases}$$

Гипотезы:

$$H_0 : \lambda = 1 \quad (\text{трансформация не требуется}) H_1 : \lambda \neq 1 \quad (\text{трансформация необходима})$$

4. РЕ-тест (на смещение модели)

Цель: Проверить, является ли модель несмещённой, то есть $\mathbb{E}(\varepsilon) = 0$.

Гипотезы:

$$H_0 : \mathbb{E}(\varepsilon) = 0 \quad (\text{нет систематической ошибки}) H_1 : \mathbb{E}(\varepsilon) \neq 0$$

t-статистика:

$$t = \frac{\bar{\varepsilon}}{s/\sqrt{n}} \sim t_{n-1}$$

5. Тест на нормальность ошибок

Вариант А: Тест Шапиро–Уилка

Гипотезы:

$$H_0 : \varepsilon \sim \mathcal{N}(0, \sigma^2) \quad (\text{остатки нормальны}) H_1 : \text{остатки не нормальны}$$

Интерпретация: Если $p\text{-value} < 0.05$, отвергаем H_0 , нарушена предпосылка нормальности.

Вариант В: Тест Жака–Бера

Статистика:

$$JB = \frac{n}{6} \left(S^2 + \frac{(K - 3)^2}{4} \right) \sim \chi^2(2)$$

где S — асимметрия, K — эксцесс.

Гипотезы:

$$H_0 : \varepsilon \sim \mathcal{N}(0, \sigma^2) H_1 : \text{остатки не из нормального распределения}$$

7 Приложение 2

[Конец рисунков]

Таблица 2: Статистические характеристики числовых признаков

	mileage	power_1	power_2	model_popularity
count	1315	1315	1315	1315
mean	25192.96	1.69	181.22	172.81
std	42067.00	0.25	39.40	117.69
min	0.00	1.30	83.00	1.00
25%	10.00	1.50	150.00	57.50
50%	3000.00	1.50	177.00	132.00
75%	26500.00	2.00	218.00	270.00
max	283000.00	2.40	245.00	319.00




Рис. 2: Распределение цен на автомобили




Рис. 3: Распределение числовых переменных




Рис. 4: Категориальные переменные (1)




Рис. 5: Категориальные переменные (2)




Рис. 6: Категориальные переменные (3)



Рис. 7: Распределение бинарных признаков




Рис. 8: Связь бинарных признаков с ценой

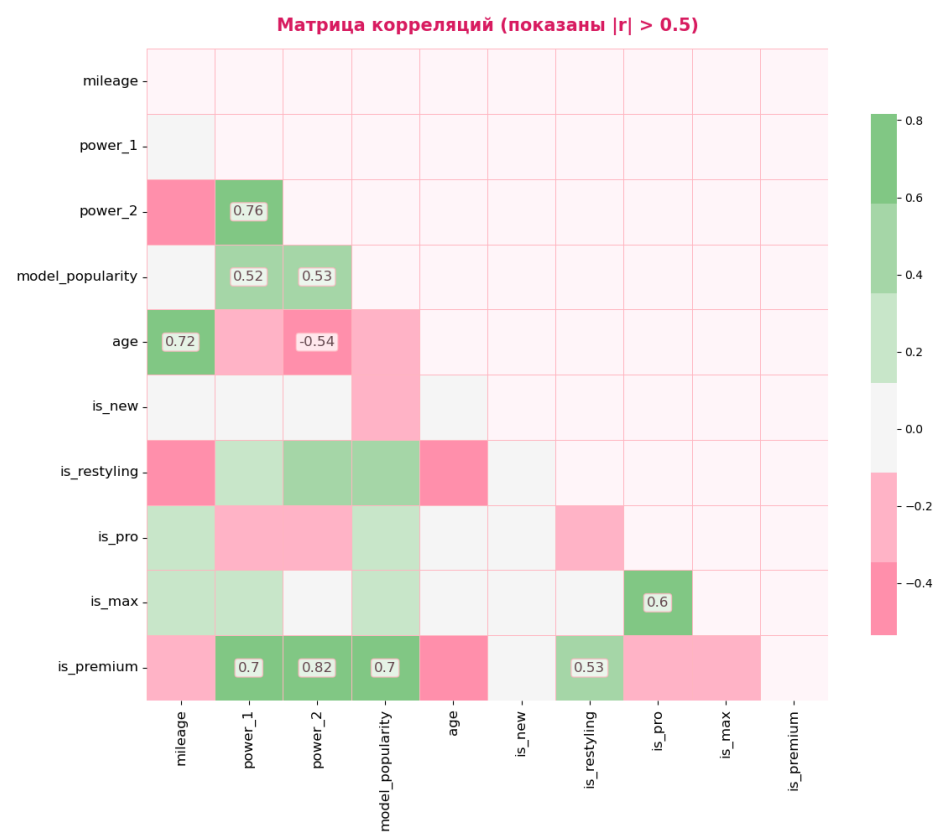


Рис. 9: Корреляция между признаками




Рис. 10: Связь бинарных и категориальных признаков




Рис. 11: Квантильная регрессия (1)




Рис. 12: Квантильная регрессия (2)




Рис. 13: Квантильная регрессия (3)




Рис. 14: Распределение остатков

OLS Regression Results						
Dep. Variable:	price	R-squared:	0.894			
Model:	OLS	Adj. R-squared:	0.893			
Method:	Least Squares	F-statistic:	1216.			
Date:	Mon, 28 Apr 2025	Prob (F-statistic):	0.00			
Time:	20:30:09	Log-Likelihood:	355.17			
No. Observations:	1315	AIC:	-690.3			
Df Residuals:	1305	BIC:	-638.5			
Df Model:	9					
Covariance Type:	HC3					
	coef	std err	t	P> t	[0.025	0.975]
const	11.3904	0.250	45.515	0.000	10.899	11.881
log_age	-0.3728	0.020	-18.903	0.000	-0.412	-0.334
brand_Geely	0.0531	0.016	3.250	0.001	0.021	0.085
is_restyling	0.0477	0.015	3.168	0.002	0.018	0.077
color_group_Холодные	0.0824	0.014	5.832	0.000	0.055	0.110
log_power_2	0.6618	0.049	13.547	0.000	0.566	0.758
city_group_Москва	0.0515	0.018	2.893	0.004	0.017	0.086
gearbox_механика	-0.7501	0.031	-24.594	0.000	-0.810	-0.690
drive_полный	0.0542	0.018	2.975	0.003	0.018	0.090
car_class_Crossover	-0.0463	0.014	-3.304	0.001	-0.074	-0.019

Рис. 15: Робастные стандартные ошибки

Таблица 3: Статистические характеристики числовых признаков

	age	generation	is_restyling	is_pro	is_max
count	1315	1315	1315	1315	1315
mean	2.08	1.06	0.45	0.20	0.08
std	2.70	0.24	0.50	0.40	0.27
min	0.00	1.00	0.00	0.00	0.00
25%	1.00	1.00	0.00	0.00	0.00
50%	1.00	1.00	0.00	0.00	0.00
75%	3.00	1.00	1.00	0.00	0.00
max	18.00	2.00	1.00	1.00	1.00

Таблица 4: Статистические характеристики числовых признаков

	is_premium	price	power_density	mileage_age_interaction	price_per_hp
count	1315	1315	1315		1315
mean	0.24	2 344 798	106.58		134 372
std	0.43	984 872	15.14		407 994
min	0.00	150 000	53.75		0
25%	0.00	1 600 000	98.00		1
50%	0.00	2 317 000	116.00		5000
75%	0.00	3 200 000	119.00		77034
max	1.00	4 599 900	163.33		4811 000

Таблица 5: Медиана числовых признаков и мода категориальных и бинарных признаков

Признак	Значение
Медиана числовых признаков и целевой переменной	
mileage	3 000
power_1	1.5
power_2	177.0
model_popularity	132.0
age	1.0
generation	1.0
power_density	116.0
mileage_age_interaction	5 000
price	2 317 000
Мода категориальных и бинарных признаков	
color	серый
color_group	Нейтральные
gearbox	робот
drive	передний
fuel_type	Бензин
city	Москва
city_group	Москва
base_model	Monjaro
car_class	Other
is_new	False
is_restyling	0
is_pro	0
is_max	0
is_premium	0